

OPTİMİZASYON ALGORİTMALARI İLE DERİN ÖĞRENME TABANLI DİYABETİK RETİNOPATİ DERECELENDİRME

Ahmet Utku ELİK, 4010940078

I. GİRİŞ

Diyabetik retinopati (DR), diyabetin retina damarlarında yol açtığı mikrovasküler hasar sonucu gelişen ve tedavi edilmediğinde geri dönüşü olmayan görme kaybına neden olabilen önemli bir komplikasyondur. Dünya Sağlık Örgütü (DSÖ), diyabeti küresel ölçekte hızla artan bir halk sağlığı problemi olarak tanımlamakta ve diyabete bağlı retinopatinin görme kaybı/körlüğün önemli nedenleri arasında yer aldığını vurgulamaktadır [1]. Güncel DSÖ verilerine göre dünya genelinde 2022 yılında yaklaşık 830 milyon kişi diyabet ile yaşamaktadır [1]. Nitekim güncel epidemiyolojik tahminler, 2020 yılında yaklaşık 103,12 milyon yetişkinin DR'ye sahip olduğunu ve bu sayının 2045 yılında 160,50 milyona ulaşabileceğini göstermektedir [2].

DR'nin küresel hastalık yükü açısından önemi yalnızca sıklığıyla sınırlı değildir; 2020 yılı için yapılan değerlendirmelerde DR'ye bağlı körlük ($\approx 1,07$ milyon) ve orta-ağır görme bozukluğu ($\approx 3,28$ milyon) gibi ciddi klinik sonuçların raporlanması, hastalığın erken tarama ve tanısının kritik rolünü ortaya koymaktadır [4]. Ayrıca meta-analiz çalışmalarında diyabet hastaları arasında DR prevalansı yaklaşık üçte bir düzeyinde bildirilmektedir [3].

DR'nin klinik tanısı geleneksel olarak oftalmoskopik muayene, fundus fotoğrafı üzerinden uzman değerlendirmesi, fluorescein anjiyografi ve optik koherens tomografi (OCT) gibi yöntemlere dayanmaktadır. Ancak bu yaklaşımlar; uzman gereksinimi, maliyet, zaman ve hasta yoğunluğu gibi nedenlerle özellikle geniş popülasyonlarda tarama yapılmasını zorlaştırabilmektedir. Bu nedenle son yıllarda bilgisayar destekli tanı sistemleri ve özellikle derin öğrenme tabanlı otomatik sınıflandırma yaklaşımları, DR taraması ve erken tanısı için yüksek potansiyel sunmaktadır. Derin öğrenme mimarilerinin (özellikle CNN tabanlı modellerin) fundus görüntülerinden ayırt edici temsilleri otomatik öğrenebilmesi, hem tanı sürecini hızlandırmakta hem de klinik iş yükünü azaltabilecek ölçeklenebilir çözümler üretmektedir [5–7].

Literatürde, DR tespitinde derin öğrenme sistemlerinin güçlü performansı çok sayıda çalışmada gösterilmiştir. Örneğin Gulshan ve arkadaşları (2016), geniş ölçekli retinal fundus görüntülerinden eğitilen derin öğrenme tabanlı bir sistemin refer edilebilir (referable) DR tespitinde yüksek doğrulukta sonuçlar üretebildiğini raporlamış, yaklaşımın tarama süreçleri için klinik uygulanabilirliğine dikkat çekmiştir [5]. Benzer şekilde Ting ve arkadaşları (2017), çok merkezli ve çok etnikli veri kümeleri üzerinde eğitilen bir derin öğrenme sisteminin yalnızca DR değil, ilişkili bazı göz hastalıklarının tespitinde de etkili olduğunu göstermiştir [6]. Öte yandan Abramoff ve arkadaşları (2018) tarafından yürütülen “pivotal trial” çalışması, bir otonom yapay zekâ sisteminin birinci basamak klinik ortamında DR taramasına yönelik pratik kullanılabilirliğini ortaya koyan önemli klinik kilometre taşlarından biri olarak değerlendirilmektedir [7].

Son yıllarda yalnızca derin ağ mimarilerinin kullanımı değil; transfer öğrenme, derin özellik çıkarımı (deep feature extraction), özellik seçimi (feature selection) ve meta-sezgisel optimizasyon yaklaşımlarının bir araya getirilmesi de giderek yaygınlaşmıştır. Özellikle etiket dağılımı dengesizliği, overfitting riski ve yüksek boyutlu temsil vektörleri gibi pratik zorluklar, klasik son-katman sınıflandırmasına alternatif olarak “derin özellik, makine öğrenmesi sınıflandırıcıları (SVM, XGBoost vb.)” ve “wrapper tabanlı özellik seçimi” gibi hibrit çözümlerin önünü açmıştır.

Bu bağlamda Canayaz (2022), önceden eğitilmiş ağlardan elde edilen derin özellikler üzerinde doğa esinli wrapper özellik seçimi stratejileri kullanarak DR sınıflandırma performansında artış sağlayan bir yaklaşım önermiştir [8]. Benzer şekilde Almansour ve çalışma arkadaşları (2025), konvolüsyonel sinir ağlarında hiperparametre aramasını otomatikleştirmek amacıyla Parçacık Sürü Optimizasyonu (PSO) tabanlı bir optimizasyon stratejisi kullanarak performans iyileştirmeleri elde etmiştir [9].

Bu çalışmada, literatürdeki bu eğilimle uyumlu olarak Diyabetik Retinopati tespitine yönelik meta-sezgisel optimizasyon ile iyileştirilmiş hibrit bir sınıflandırma yöntemi geliştirilmiştir. Açık kaynak fundus görüntülerinden oluşan geniş ölçekli veri seti kullanılarak DR'nin ikili sınıflandırma (negatif/pozitif) problemi ele alınmış; EfficientNetB0 ile derin özellik çıkarımı gerçekleştirilmiş ve SVM ile XGBoost sınıflandırıcıları üzerinden özellik seçimi (PSO/ABC) ve hiperparametre optimizasyonu (PSO/ABC) adımları uygulanmıştır. Deneyisel sonuçlarda, özellikle XGBoost tabanlı modellerde Macro-F1 ve ROC-AUC değerlerinde istikrarlı bir artış gözlenmiş ve meta-sezgisel optimizasyonun sistem performansını iyileştirmeye katkı sağladığı görülmüştür.

II. METODOLOJİ VE MATERYAL

Bu çalışmada, fundus görüntülerinden Diyabetik Retinopati (DR) var/yok tespitini gerçekleştirmek amacıyla transfer öğrenme, meta-sezgisel optimizasyon ve makine öğrenmesi sınıflandırıcılarını bir araya getiren hibrit bir yaklaşım önerilmiştir. Önerilen yöntem, hem derin öğrenme modellerinin güçlü temsil kabiliyetinden yararlanmayı hem de seçilen özellik alt kümesi ve hiperparametre optimizasyonu ile sınıflandırıcı performansını artırmayı hedeflemektedir. Çalışmanın genel metodolojisi üç temel fazdan oluşmaktadır:

1. Derin Özellik Çıkarımı (Deep Feature Extraction):

Ön eğitilmiş transfer öğrenme modeli olan EfficientNetB0 kullanılarak fundus görüntülerinden ayırtıcı derin özellik vektörleri elde edilmiştir.

2. Özellik Seçimi (Feature Selection):

Derin özellik uzayındaki gereksiz veya düşük katkılı bileşenleri elimine etmek amacıyla, meta-sezgisel optimizasyon algoritmaları ile binary maske tabanlı özellik seçimi uygulanmıştır.

3. Sınıflandırma ve Hiperparametre Optimizasyonu:

Seçilen özellikler üzerinde sınıflandırma işlemi, SVM ve XGBoost modelleri ile gerçekleştirilmiş; ayrıca bu modellerin hiperparametreleri meta-sezgisel optimizasyon ile belirlenerek doğrulama başarımının artırılması hedeflenmiştir.

A. Derin Özellik Çıkarımı (Deep Feature Extraction)

Bu çalışmada fundus görüntülerinden ayırt edici temsiller elde edebilmek amacıyla transfer öğrenme tabanlı derin özellik çıkarımı (deep feature extraction) yaklaşımı kullanılmıştır. Transfer öğrenme, büyük ölçekli veri kümeleri üzerinde önceden eğitilmiş derin ağların öğrenmiş olduğu genel görsel temsillerin, hedef probleme aktarılması prensibine dayanmaktadır. Bu yaklaşım özellikle tıbbi görüntüleme alanında, etiketli veri miktarının sınırlı olabildiği senaryolarda eğitim maliyetini azaltması ve genelleme performansını artırabilmesi nedeniyle yaygın şekilde tercih edilmektedir [10]. Bu kapsamda çalışmada, hem doğruluk hem de hesaplama verimliliği açısından güçlü bir mimari olarak öne çıkan EfficientNetB0 modeli temel özellik çıkarıcı ağ (backbone) olarak seçilmiştir.

EfficientNet ailesi, ağırlıklı olarak derinliği, genişliği ve giriş çözünürlüğünü birlikte ölçekleyen “compound scaling” yaklaşımı ile daha dengeli ve etkili bir modelleme sunmaktadır [11]. Bu özellik, EfficientNetB0’ın tıbbi görüntü sınıflandırma problemlerinde hem pratik eğitim süresi hem de temsil gücü bakımından uygun bir seçenek olmasını sağlamaktadır. Bu çalışmada EfficientNetB0 modeli, ImageNet üzerinde önceden eğitilmiş ağırlıklar kullanılarak sisteme entegre edilmiş ve sınıflandırma başlığı (classification head) çıkarılarak model yalnızca “özellik çıkarıcı” olarak yapılandırılmıştır. Böylece modelin son konvolüsyonel katmanlarından elde edilen yüksek seviyeli öznitelikler, sınıflandırma aşamasına giriş olarak kullanılacak sabit boyutlu bir temsile dönüştürülmüştür.

Özellik çıkarımı sürecinde fundus görüntüleri, ağırlıklı olarak girişine uygun olacak şekilde yeniden boyutlandırılmış ve standart ön işleme adımları uygulanmıştır. Ardından EfficientNetB0 mimarisinde yer alan son özellik haritaları üzerinden Global Average Pooling (GAP) yaklaşımı kullanılarak her bir görüntü için sabit uzunlukta bir özellik vektörü elde edilmiştir. EfficientNetB0 için bu vektör boyutu tipik olarak 1280 olup, her bir görüntünün yüksek seviyeli görsel-temsillerini içeren bir derin öznitelik uzayı sunmaktadır [11]. Elde edilen bu derin özellikler daha sonraki aşamalarda iki amaçla kullanılmıştır: (i) meta-sezgisel algoritmalar ile daha kompakt ve ayırtıcı bir özellik alt kümesi seçmek ve (ii) seçilen özellikler üzerinden SVM ve XGBoost gibi sınıflandırıcıların eğitimini gerçekleştirmek.

Bu aşamanın temel avantajı, klasik yaklaşımlarda kullanılan özelliklere kıyasla, derin ağırlıklı retina üzerinde DR ile ilişkili olabilecek lezyon örüntülerini temsil edebilecek daha zengin bir özellik uzayı oluşturabilmesidir. Böylelikle sınıflandırma fazına daha ayırtıcı bir temsil aktarılmış ve sistemin genel performansının artırılması hedeflenmiştir.

B. Özellik Seçimi (Feature Selection)

Bu çalışmada EfficientNetB0 modeli ile elde edilen derin özellik vektörleri, yüksek boyutlu bir temsil uzayı sunduğundan (örneğin 1280 boyutlu öznitelik vektörü), bu uzayda tekrarlı, gürültülü veya sınıflandırma performansına düşük katkı sağlayan bileşenlerin bulunması olasıdır. Bu durum, özellikle geleneksel makine öğrenmesi sınıflandırıcıları kullanıldığında hem hesaplama maliyetini artırabilmekte hem de modelin genelleme başarımını olumsuz etkileyebilmektedir. Bu nedenle çalışmada, sınıflandırma performansını

artırmak ve daha kompakt bir temsil elde etmek amacıyla özellik seçimi (feature selection) aşaması sisteme dahil edilmiştir.

Bu çalışma kapsamında özellik seçimi, her bir özelliğin seçilip seçilmeyeceğini belirleyen ikili (binary) maske temsili ile modellenmiştir. Buna göre, her çözüm adayı değeri 0/1 olan dizi biçiminde tanımlanmış ve ilgili indisin 1 olması durumunda ilgili özelliğin korunduğu, 0 olması durumunda ise çıkarıldığı kabul edilmiştir. Böylece, seçilen özellik alt kümesi ile yeni bir temsil matrisi oluşturulmuş ve sınıflandırma modeli bu azaltılmış özellik uzayında eğitilmiştir. Bu aşamada her çözüm adayının uygunluğu (fitness), doğrulama kümesi üzerinde elde edilen Macro-F1 değeri ile ölçülmüş ve amaç, Macro-F1 skorunu maksimize eden özellik alt kümesini bulmak olarak belirlenmiştir. Özellikle Macro-F1 metriği, sınıflar arasında olası dengesizlik durumlarında her sınıfa eşit önem vererek daha güvenilir bir performans değerlendirmesi sunduğundan tercih edilmiştir.

Özellik seçimi sürecinde meta-sezgisel optimizasyon algoritmaları kullanılmıştır. Meta-sezgisel yöntemler, yüksek boyutlu ve doğrusal olmayan optimizasyon problemlerinde geleneksel türev tabanlı yöntemlere göre daha esnek çözümler sunabilmekte ve çok modlu (multimodal) arama uzaylarında etkili performans gösterebilmektedir [12]. Bu çalışmada iki farklı sürü zekâsı temelli meta-sezgisel yöntem değerlendirilmiştir: Parçacık Sürü Optimizasyonu (PSO) ve Yapay Arı Kolonisi (ABC).

PSO algoritması, sürü içerisindeki parçacıkların kişisel en iyi (pbest) ve küresel en iyi (gbest) çözüme göre hareket etmesi prensibiyle çalışan ve birçok optimizasyon probleminde başarılı sonuçlar üreten bir yöntemdir [13]. Bu çalışmada PSO’da her parçacık bir özellik maske adayını temsil etmiş, her iterasyonda güncellenen aday maske ile seçilen öznitelikler üzerinden sınıflandırıcı performansı ölçülerek en iyi çözüme doğru yakınsama sağlanmıştır.

Ayrıyeten ABC algoritması, işçi arılar, gözlemci arılar ve izci arılar aracılığıyla çözüm uzayında keşif ve sömürü dengesini kuran ve özellikle sayısal optimizasyon problemlerinde yaygın kullanılan bir yöntemdir [14]. ABC’de her besin kaynağı bir özellik alt kümesini temsil etmiş, aday çözümün iyileştirilmesi lokal komşuluk araması ile gerçekleştirilmiş ve belirli bir süre iyileşmeyen çözümler izci arılar ile yeniden başlatılarak keşif kapasitesi artırılmıştır.

C. Makine Öğrenme Tabanlı Sınıflandırma Yöntemi

Bu çalışmada sınıflandırma aşaması, EfficientNetB0 modeli üzerinden elde edilen derin özellik temsillerinin (deep features) DR negatif / DR pozitif olarak sınıflandırılmasını hedefleyen karar mekanizmasının oluşturulması amacıyla tasarlanmıştır. Bu amaç doğrultusunda, literatürde yüksek boyutlu özellik uzaylarında başarılı genelleme performansı sunmasıyla bilinen Destek Vektör Makineleri (SVM) ile güçlü bir topluluk öğrenme yaklaşımı olan XGBoost sınıflandırıcısı tercih edilmiştir. Sınıflandırıcıların seçilme motivasyonu, derin özelliklerin doğrusal veya doğrusal olmayan karar sınırlarıyla etkin şekilde ayrıştırılabilmesi ve farklı modelleme yaklaşımlarının karşılaştırmalı olarak analiz edilebilmesidir.

Support Vector Machine (SVM)

SVM, sınıflar arasındaki ayrımı en yüksek marjın ile sağlayan optimum hiper-düzlemi öğrenmeye dayanan güçlü bir sınıflandırma yöntemidir ve özellikle yüksek boyutlu veri temsillerinde etkili sonuçlar üretebilmektedir [15]. Bu çalışmada hesaplama verimliliği ve ölçeklenebilirlik gereksinimleri nedeniyle doğrusal çekirdekli SVM

yaklaşımı temel alınmış; uygulamada LinearSVC kullanılarak eğitim süresi iyileştirilmiştir. Doğrusal SVM çözümlerinde eğitim verisi boyutunun artmasıyla birlikte klasik SVM eğitim süreçleri maliyetli hale gelebileceğinden, büyük veri ölçeklerinde doğrusal SVM çözümlerinin kullanımı pratik avantaj sağlamaktadır [16].

Bu çalışmada SVM tabanlı sınıflandırma, özelliklerin ölçek farklarından etkilenmemesi ve optimizasyon sürecinin daha kararlı ilerlemesi için, derin özellik vektörleri eğitim öncesinde z-skor normalizasyonu ile standartlaştırılmıştır.

Extreme Gradient Boosting (XGBoost)

XGBoost, gradyan artırma (gradient boosting) prensibiyle çok sayıda zayıf öğrenciyi (çoğunlukla karar ağaçlarını) ardışık biçimde birleştirerek güçlü bir tahminleyici oluşturur ve modern sınıflandırma problemlerinde yüksek başarımla öne çıkmaktadır [17]. XGBoost'un temel üstünlüğü, doğrusal olmayan karar sınırlarını etkili biçimde modelleyebilmesi, düzenleme (regularization) mekanizmaları sayesinde aşırı öğrenmeyi azaltabilmesi ve büyük veri üzerinde hızlı öğrenme imkânı sunmasıdır [16].

Bu çalışmada XGBoost modeli, derin özellikler üzerinde hem baseline performansın ölçülmesi hem de meta-sezgisel optimizasyon ile hiperparametre ayarlaması yapılarak en iyi doğrulama başarımının elde edilmesi amacıyla kullanılmıştır.

D. Hiperparametre Optimizasyonu

Bu çalışmada sınıflandırma fazında kullanılan SVM ve XGBoost modellerinin başarımı, yalnızca eğitim verisiyle öğrenilen parametreler tarafından değil, aynı zamanda modelin kapasitesini ve karar sınırını doğrudan etkileyen hiperparametreler tarafından belirlenmektedir. Hiperparametre seçimi, özellikle veri kümesinin sınıf dağılımı, özellik uzayının boyutu ve problem karmaşıklığı gibi faktörlere bağlı olarak sınıflandırıcının aşırı öğrenme (overfitting) veya yetersiz öğrenme (underfitting) eğilimlerini belirleyebildiği için kritik bir adımdır. Bu nedenle çalışmada, geleneksel sabit hiperparametre seçimi yerine hiperparametrelerin otomatik olarak optimize edilmesi hedeflenmiştir. Literatürde de hiperparametre optimizasyonunun, özellikle tıbbi görüntü sınıflandırma problemlerinde daha yüksek genelleme başarımı sağlayabildiği çeşitli çalışmalarda gösterilmiştir [18].

Bu kapsamda hiperparametre optimizasyonu problemi, doğrulama kümesi üzerindeki performansı maksimize etmeyi amaçlayan bir optimizasyon problemi olarak ele alınmıştır. Bu yaklaşımda amaç fonksiyonu, sınıflandırıcıların doğrulama verisi üzerindeki başarımını ölçen bir metrik kullanılarak tanımlanmış ve bu çalışmada özellikle sınıflar arası dengeyi daha iyi yansıtmaları nedeniyle Macro-F1 metriği optimize edilen hedef fonksiyon olarak tercih edilmiştir. Böylece, her bir hiperparametre kombinasyonu bir aday çözüm olarak değerlendirilmiş ve bu kombinasyonun doğrulama başarımına göre "uygunluk" değeri (fitness) belirlenmiştir.

Bu çalışmada SVM tarafında hiperparametre optimizasyonu, özellikle karar sınırını belirleyen ve düzenleme gücünü kontrol eden C parametresi üzerinde yoğunlaştırılmıştır. C değerinin küçük seçilmesi daha güçlü düzenleme sağlayarak genelleme başarımını artırabilirken, büyük seçilmesi modelin eğitime daha fazla uyum sağlamasına neden olabilmektedir. Dolayısıyla SVM için C parametresinin doğru belirlenmesi, özellikle derin özellikler gibi yüksek boyutlu temsillerde kritik öneme sahiptir.

Tablo 1. SVM/XGBoost için Hiperparametre Aralıkları

Model	Hiperparametre	Aralık
LinearSVM	C	0.0001 – 10.0
XGBoost	n_estimator	200 – 800
	max_depth	3 – 7
	learning_rate	0.02 – 0.12
	subsample	0.7 – 1.0
	colsample_bytree	0.7 – 1.0

XGBoost tarafında ise model kapasitesini belirleyen ağaç sayısı (n_estimators), ağaç derinliği (max_depth) ve öğrenme dinamiklerini kontrol eden learning_rate gibi hiperparametreler başta olmak üzere; subsample ve colsample_bytree gibi örnekleme parametreleri optimize edilmiştir. Bu parametreler, modelin genelleme başarımı ile hesaplama maliyeti arasında denge kurmada belirleyici olduğu için hiperparametre optimizasyonu sürecine dahil edilmiştir.

E. Önerilen Yöntem

Bu çalışmada Diyabetik Retinopati (DR) tespiti için transfer öğrenme tabanlı derin özellik çıkarımı, meta-sezgisel optimizasyon tabanlı özellik seçimi ve optimize edilmiş sınıflandırma adımlarını birleştiren hibrit bir yöntem önerilmiştir.


Yöntemin ilk aşamasında, ImageNet üzerinde önceden eğitilmiş EfficientNetB0 mimarisi özellik çıkarıcı olarak kullanılmış ve her bir fundus görüntüsü için sabit boyutlu derin özellik vektörleri elde edilmiştir. İkinci aşamada, derin özellik uzayındaki gereksiz veya düşük katkılı bileşenleri elemek amacıyla binary maske tabanlı wrapper özellik seçimi uygulanmıştır. Bu işlemde amaç fonksiyonu olarak doğrulama verisi üzerinde Macro-F1 metriği maximize edilmiş ve arama sürecinde PSO ile ABC meta-sezgisel algoritmalarından yararlanılmıştır.

Son aşamada ise seçilen özellik alt kümesi üzerinde SVM ve XGBoost sınıflandırıcıları eğitilmiş, ayrıca bu modellerin hiperparametreleri meta-sezgisel optimizasyon ile belirlenerek doğrulama başarımı artırılmaya çalışılmıştır. Böylece önerilen yöntem, "derin temsil + özellik seçimi + optimize edilmiş sınıflandırıcı" bileşenlerinden oluşan bütüncül bir karar destek sistemi şeklinde yapılandırılmıştır.

F. "Eyepacs, Aptos, Messidor Diabetic Retinopathy" Veri Seti

Bu çalışmada Diyabetik Retinopati (DR) tespiti problemi için Kaggle platformunda açık erişimle paylaşılan "EyePACS, APTOS, MESSIDOR Diabetic Retinopathy" veri seti kullanılmıştır [19]. Veri seti, farklı kaynaklardan derlenmiş fundus görüntülerini bir araya getirerek gerçek dünya koşullarında karşılaşılabilecek çekim cihazı farklılıkları, ışık/kontrast değişimleri ve görüntü kalitesi çeşitliliğini içeren geniş ölçekli bir örneklem sunmaktadır. Bu yönüyle veri seti, DR sınıflandırma sistemlerinin genellenebilirliğini değerlendirmek için uygun bir test ortamı sağlamaktadır.

Veri setinde her bir fundus görüntüsü, klinik DR şiddet düzeyine göre 0-4 aralığında beş sınıfa ayrılmıştır. Bu etiketler genel olarak 0: normal, 1: hafif, 2: orta, 3: şiddetli ve 4: proliferatif DR düzeylerini temsil etmektedir. Çalışmada kullanılan veri seti toplam 143,669 görüntüden oluşmakta ve görüntüler yaklaşık 600×600 piksel çözünürlükte bulunmaktadır.



a) DR_Negative b) DR_Positive
Şekil 1. Örnek DR Veri Seti Görşelleri

Bu proje kapsamında hedef problem, çok sınıflı sınıflandırmadan ziyade klinik açıdan daha pratik bir senaryo olan DR var/yok (ikili sınıflandırma) biçiminde ele alınmıştır. Bu amaçla sınıflar yeniden gruplandırılmış ve DR_negatif = {0,1} ile DR_pozitif = {2,3,4} olarak tanımlanmıştır. Böyle bir dönüşüm, hem modelin karar sürecini daha sade hâle getirmekte hem de veri dengesizliğinin etkisini azaltarak daha kararlı bir eğitim süreci sağlamaktadır. Bu doğrultuda, deneysel süreci daha yönetilebilir hâle getirmek ve sınıflar arası örnek sayısını dengelemek için özgün veri setinden rastgele örnekleme ile 20,000 görüntüden oluşan dengeli bir alt veri kümesi (DR_BINARY_20K) oluşturulmuştur.

Çalışmada, veri setinin %70'i eğitim, %15'i doğrulama ve %15'i test olacak şekilde ayrılmıştır.

III. DENEYSEL ÇALIŞMALAR

A. Deneysel Kurulum

Bu çalışma Google Colab ortamında NVIDIA Tesla T4 GPU donanımı ve Python tabanlı bir çalışma akışıyla yürütülmüştür. Derin öğrenme tabanlı baselines (EfficientNetB0) için TensorFlow/Keras altyapısı kullanılmış, klasik makine öğrenmesi sınıflandırıcıları ve performans metrikleri için scikit-learn kütüphanesinden yararlanılmıştır. XGBoost tabanlı deneyler ise XGBoost kütüphanesi üzerinden gerçekleştirilmiştir. Deneylerin tekrarlanabilirliğini artırmak amacıyla rastgelelik kontrolü sağlanmış ve tüm süreçlerde sabit bir seed (SEED=42) değeri kullanılmıştır. Modelin eğitiminde ve test işlemlerinde kullanılacak olan veri seti ilk olarak Google Drive'a aktarılıp sonrasında Google Colab ile entegrasyonu sağlanmıştır.

B. Deney Planı

Deneysel süreç aşağıdaki tabloda verildiği üzere üç temel senaryo üzerinden gerçekleştirilmiştir;

Tablo 2. Deney Senaryoları

Deney	Açıklama
Senaryo - 1	EfficientNetB0 üzerine eklenen sınıflandırma başlığı ile uçtan uca bir CNN baseline modeli eğitilmiştir
Senaryo - 2	EfficientNetB0 yalnızca özellik çıkarıcı olarak kullanılmış, her görüntü için elde edilen 1280 boyutlu derin özellik vektörleri üzerinden SVM ve XGBoost baseline sınıflandırıcıları eğitilmiştir.
Senaryo - 3	Derin özellikler üzerinde meta-sezgisel optimizasyon kullanılarak önce özellik seçimi (PSO/ABC ile binary maske) yapılmış, daha sonra sınıflandırıcıların hiperparametreleri yine meta-sezgisel yöntemlerle optimize edilmiştir.

Sonuçların anlamlı şekilde karşılaştırılabilmesi için tüm yöntemlerde aynı train/val/test ayrımı korunmuş, nihai performans test kümesi üzerinde raporlanmıştır.


C. Deneysel Sonuçlar

Toplamda 3 farklı senaryo kapsamında gerçekleştirilen deneylerdeki modeller eğitildikten sonra her bir sınıfa ait 1500, toplamda 3000 adet test veri seti ile performansları test edildi.

Geliştirilen modellere ait performans metrikleri ile Karmaşıklık Matrisi ve ROC Eğri grafikleri her bir senaryo için aşağıda gösterilmektedir.


Senaryo - 1

İlk senaryoda ImageNet veri seti ile önceden eğitilmiş EfficientNetB0 modelindeki sınıflandırma katmanı çıkarılıp bir özellik çıkarıcı (backbone) olarak kullanılıp, sınıflandırma katmanına basit bir tam bağlantılı (FC) katman eklenip elde edilen CNN Baseline modelinin eğitimi gerçekleştirildi. Modelin eğitim aşamasındaki accuracy/loss grafiği aşağıda verilmiştir.




Şekil 8. CNN Baseline modelin eğitim aşamasındaki Accuracy/Loss grafiği.


Eğitilen CNN Baseline modelin test veri setleri ile gerçekleştirilen test sonuçları aşağıdaki grafiklerde verilmiştir.



Şekil 8. CNN Baseline model için karmaşıklık matrisi.



Şekil 8. CNN Baseline model için ROC eğri grafiği.



Şekil 8. SVM CNN Baseline model için ROC eğri grafiği.

Senaryo – 2.1

İkinci senaryo kapsamında, EfficientNetB0 modeli bir derin özellik çıkarıcı olarak kullanılarak fundus görüntülerinden 1280 boyutuna sahip derin özellik vektörleri elde edildikten sonra sınıflandırıcı olarak SVM ve XGBoost kullanılan 2 farklı modelin eğitim ve test işlemleri gerçekleştirilmiştir.

Eğitim aşamasında SVM ve XGBoost sınıflandırıcıların Macro-F1 ve AUC değerleri aşağıdaki tabloda verilmiştir.

Tablo 3. EfficientNetB0 özellik çıkarımı sonrası SVM ve XGBoost sınıflandırıcı modellerin eğitim aşamasındaki Macro-F1 ve AUC değerleri.


	Macro-F1	AUC
SVM	0.8118	0.8766
XGBoost	0.8207	0.8966

Modellerin test veri setleri ile elde edilen Macro-F1 ve AUC performans metrikleri aşağıdaki tabloda verilmiştir.


Tablo 4. EfficientNetB0 özellik çıkarımı sonrası SVM ve XGBoost sınıflandırıcı modellerin test aşamasındaki Macro-F1 ve AUC değerleri.

	Macro-F1	AUC
SVM	0.7876	0.8591
XGBoost	0.8126	0.8815


Eğitilen SVM CNN Baseline modelin test veri setleri ile gerçekleştirilen test sonuçları aşağıdaki grafiklerde verilmiştir.



Şekil 8. SVM CNN Baseline model için karmaşıklık matrisi.



Şekil 8. SVM CNN Baseline model için karmaşıklık matrisi.



Şekil 8. SVM CNN Baseline model için ROC eğri grafiği.

Senaryo – 2.2


İkinci senaryonun devamında, Senaryo-2.1’de elde edilen derin özellik vektörlerinden PSO algoritması kullanılarak özellik seçimi sonrası 647 adet yeni özellik seçildikten sonra yine sınıflandırma algoritması olarak SVM ve XGBoost kullanılarak 2 farklı modelin eğitim ve test işlemleri

gerçekleştirilmiştir. Test aşamasında SVM ve XGBoost sınıflandırıcıların Macro-F1 ve AUC değerleri aşağıdaki tabloda verilmiştir.


Tablo 3. EfficientNetB0 özellik çıkarımı ve PSO özellik seçimi sonrası SVM ve XGBoost sınıflandırıcı modellerin test aşamasındaki Macro-F1 ve AUC değerleri.

	Macro-F1	AUC
SVM	0.7932	0.8585
XGBoost	0.8073	0.8784

Eğitilen PSO_FS_SVM CNN Baseline modelin test veri setleri ile gerçekleştirilen test sonuçları aşağıdaki grafiklerde verilmiştir.




Şekil 8. PSO_FS_SVM CNN Baseline model için karmaşıklık matrisi.




Şekil 8. PSO_FS_SVM CNN Baseline model için ROC eğri grafiği.

Eğitilen PSO_FS_XGB CNN Baseline modelin test veri setleri ile gerçekleştirilen test sonuçları aşağıdaki grafiklerde verilmiştir.



Şekil 8. PSO_FS_XGB CNN Baseline model için karmaşıklık matrisi.



Şekil 8. PSO_FS_XGB CNN Baseline model için ROC eğri grafiği.

Senaryo – 3

Üçüncü senaryo kapsamında, Senaryo-2’de özellik çıkarımı ve PSO ile özellik seçimi sonrası elde edilen yeni özellikler ile sınıflandırma algoritması olarak kullanılan SVM ve XGBoost algoritmalarının hiperparametre optimizasyonları yine PSO algoritması ile belirlendikten sonra 2 farklı modelin eğitim ve test işlemleri gerçekleştirilmiştir.

PSO ile gerçekleştirilen hiperparametre optimizasyon sonrası SVM ve XGBoost algoritmaları için seçilen hiperparametreler aşağıdaki tabloda verilmiştir.

Tablo 1. SVM/XGBoost için seçilen hiperparametre değerleri


Model	Hiperparametre	Aralık	Best
LinearSVM	C	0.0001 – 10.0	0.0014
XGBoost	n_estimator	200 – 800	800
	max_depth	3 – 7	5
	learning_rate	0.02 – 0.12	0.12
	subsample	0.7 – 1.0	0.85
	colsample_bytree	0.7 – 1.0	0.7

Test aşamasında SVM ve XGBoost sınıflandırıcıların Macro-F1 ve AUC değerleri aşağıdaki tabloda verilmiştir.


Tablo 3. EfficientNetB0 özellik çıkarımı ve PSO özellik seçimi sonrası SVM ve XGBoost sınıflandırıcı modellerin test aşamasındaki Macro-F1 ve AUC değerleri.

	Macro-F1	AUC
SVM	0.8013	0.8758
XGBoost	0.8064	0.8780

Eğitilen SVM_FS_PSO_OPT CNN Baseline modelin test veri setleri ile gerçekleştirilen test sonuçları aşağıdaki grafiklerde verilmiştir.




Şekil 8. SVM_FS_PSO_OPT CNN Baseline model için karmaşıklık matrisi.




Şekil 8. SVM_FS_PSO_OPT CNN Baseline model için ROC eğri grafiği.

Eğitilen XGB_FS_PSO_OPT CNN Baseline modelin test veri setleri ile gerçekleştirilen test sonuçları aşağıdaki grafiklerde verilmiştir.



Şekil 8. XGB_FS_PSO_OPT CNN Baseline model için karmaşıklık matrisi.



Şekil 8. XGB_FS_PSO_OPT CNN Baseline model için ROC eğri grafiği.

IV. DEĞERLENDİRME

Bu çalışma kapsamında Diyabetik Retinopati (DR) tespiti problemi için ImageNet üzerinde önceden eğitilmiş EfficientNetB0 modeli derin özellik çıkarıcı olarak kullanılmış ve hem CNN tabanlı baseline yaklaşım hem de klasik makine öğrenmesi tabanlı hibrit yapılar karşılaştırılmıştır. EfficientNetB0 ile oluşturulan CNN baseline model, test aşamasında AUC=0.8713 elde ederek ikili sınıflandırma problemi için güçlü bir başlangıç performansı sunmuştur. Bununla birlikte, EfficientNetB0'den elde edilen 1280 boyutlu derin özellik vektörlerinin SVM ve XGBoost ile sınıflandırılması, özellikle XGBoost tarafında daha başarılı sonuçlar üretmiş (TEST Macro-F1=0.8126, AUC=0.8815) ve derin özellik + klasik sınıflandırıcı yaklaşımının bu problem için etkili bir strateji olduğunu göstermiştir.

İkinci senaryonun devamında PSO ile özellik seçimi uygulanarak özellik sayısı 1280'den 647'ye düşürülmüş, böylece boyut azaltımı sağlanırken performans büyük ölçüde korunmuştur (XGBoost Macro-F1=0.8073, AUC=0.8784). Üçüncü senaryoda ise PSO ile hem özellik seçimi hem de hiperparametre optimizasyonu gerçekleştirilmiş, özellikle SVM tarafında iyileşme gözlenirken (Macro-F1=0.8013, AUC=0.8758), XGBoost tarafında baseline'a kıyasla kazanımın sınırlı kaldığı görülmüştür (Macro-F1=0.8064, AUC=0.8780). Bu sonuçlar, meta-sezgisel optimizasyon yöntemlerinin özellikle boyut indirgeme ve belirli modellerde performans artırımı açısından fayda sağlayabildiğini,

ancak kazanımın arama uzayı, doğrulama stratejisi ve amaç fonksiyonuna bağlı olarak değişebildiğini göstermektedir

V. KAYNAKLAR

- [1] World Health Organization. (2024). Diabetes – Key facts. World Health Organization.
- [2] Teo, Z. L., Tham, Y.-C., Yu, M., et al. (2021). Global prevalence of diabetic retinopathy and projection of burden through 2045. *Ophthalmology / related epidemiological synthesis*.
- [3] Hashemi, H., Pakzad, R., Yekta, A., et al. (2022). Global and regional prevalence of diabetic retinopathy: A comprehensive systematic review and meta-analysis. *Ophthalmic Epidemiology (systematic review / meta-analysis)*.
- [4] GBD-based) Global burden of diabetic retinopathy and vision loss (2020 estimates). *Eye (Nature Portfolio)*.
- [5] Gulshan, V., Peng, L., Coram, M., et al. (2016). Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. *JAMA*, 316(22), 2402–2410.
- [6] Ting, D. S. W., Cheung, C. Y., Lim, G., et al. (2017). Development and validation of a deep learning system for diabetic retinopathy and related eye diseases using retinal images from multiethnic populations with diabetes. *JAMA*, 318(22), 2211–2223.
- [7] Abramoff, M. D., Lavin, P. T., Birch, M., Shah, N., & Folk, J. C. (2018). Pivotal trial of an autonomous AI-based diagnostic system for detection of diabetic retinopathy in primary care offices. *npj Digital Medicine*, 1, 39.
- [8] Canayaz, M. (2022). Classification of diabetic retinopathy with feature selection over deep features using nature-inspired wrapper methods. *Applied Soft Computing*.
- [9] Almansour, N., et al. (2025). Applying particle swarm optimization to hyperparameter tuning of convolutional neural networks to diagnose diabetic retinopathy. *PeerJ (or PeerJ Computer Science)*.
- [10] Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359.
- [11] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the 36th International Conference on Machine Learning (ICML)* (pp. 6105–6114).
- [12] Xue, B., Zhang, M., Browne, W. N., & Yao, X. (2016). A survey on evolutionary computation approaches to feature selection. *IEEE Transactions on Evolutionary Computation*, 20(4), 606–626.
- [13] Kennedy, J., & Eberhart, R. (1995). Particle swarm optimization. In *Proceedings of ICNN'95 - International Conference on Neural Networks* (pp. 1942–1948). IEEE.
- [14] Karaboga, D. (2005). An idea based on honey bee swarm for numerical optimization (Technical Report TR06). Erciyes University.
- [15] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.
- [16] Fan, R.-E., Chang, K.-W., Hsieh, C.-J., Wang, X.-R., & Lin, C.-J. (2008). LIBLINEAR: A library for large linear classification. *Journal of Machine Learning Research*, 9, 1871–1874.
- [17] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM.
- [18] Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305.
- [19] Kaggle. (2026). Eyepacs, Aptos, Messidor Diabetic Retinopathy. Erişim: <https://www.kaggle.com/datasets/ascanipek/eyepacs-aptos-messidor-diabetic-retinopathy/data>